DDSP-SVC를 활용한 AI 음성 변환 모델

송정훈[O], 노병준[*], 우지영[*]
[O]순천향대학교 AI·빅데이터학과,
[*]순천향대학교 AI·빅데이터학과
e-mail: sjhon121215@sch.ac.kr[O], {powernoh, jywoo}@sch.ac.kr[*]

AI speech conversion model using DDSP-SVC

Jeong-Hoon Song[O], Byeong-Joon Noh[*], Ji-Young Woo[*]
[O]Dept. of AI and Bigdata, SoonChunHyang University,
[*]Dept. of AI and Bigdata, SoonChunHyang University

● 요 약 ●

본 논문에서는 DDSP-SVC(Differentiable Digital Signal Processing for Singing Voice Conversion)를 활용한 AI 음성 변환 모델을 사용한다. AI 기술의 발전으로 노래 부르기를 구현할 수 있게 되었고, 이를 활용한 SVC(Singing Voice Conversion) 기술이 주목받고 있다. 본 논문에서는 비교적 낮은 컴퓨터 사양에서도 작동하며, 데이터의 양이 부족해도 양질의 음성을 생성할 수 있는 DDSP-SVC 모델을 활용하였다. 무반주 라이브 데이터를 수집하고 전처리 과정을 거쳐 모델에 학습시켰으며, 로이킴의 노래 10곡을 대상으로 변환 실험을 진행하였다. 실험 결과, F0 Perason Correlation(FPC) 평가지표를 사용하여 최소 0.65에서 최대 0.977의 높은 유사성을 보였다. 이는 적은 데이터로도 성공적인 음성 변환이 가능함을 시사한다. 향후 연구에서는 일상 대화 데이터를 추가로 학습시켜 더욱 다양한 음성 변환을 목표로 한다.

키워드: AI 음성 변환, DDSP-SVC, Singing Voice Conversion(SVC)

I. Introduction

최근 AI 기술의 발전으로 인간의 창작활동 중 하나인 노래부르기를 구현할 수 있게 되었다. 이러한 기술을 활용하여 AI가 부른 음악과 가수가 직접 부른 노래를 비교하는 TV프로그램이 등장하고, Youtube에 자신이 좋아하는 가수의 목소리로 듣고 싶은 노래를 들을 수 있도록 하는 음원 커버에 대한 관심도 늘어나고 있다.

AI로 노래 부르기가 가능하게 한 기술은 SVC(Singing voice conversion)라고 불리는 노래의 목소리만 다른 사람의 목소리로 바꾸는 기술이다. 이러한 SVC 모델에 대한 연구가 계속해서 진행되고 있고 Diff-SVC(Diffusion based Singing Voice Conversion)[1], SO-VITS-SVC(SoftVC VITS Singing Voice Conversion)[2], DDSP-SVC(Differentiable Digital Signal Processing Singing Voice Conversion)[3] 와 같은 다양한 모델이 존재한다. 본 실험에서는 비교적 낮은 컴퓨터 사양에서 동작하고 훈련 시간도 단축하며 적은 양의 데이터로도 양질의 결과값을 얻을 수 있는 DDSP-SVC 모델을 활용한다.

II. Experiments

1. 데이터

1.1 데이터 수집

본 실험에서 모델에 학습시킬 데이터는 무반주 라이브 데이터이다. 목소리 변환에 흔히 사용하는 MR과 보컬을 분리한 데이터나 믹싱 프로그램을 통한 데이터를 사용하는데, 이와 같은 방법으로 데이터를 수집할 시 반주가 있는 노래에서 보컬을 추출하는 작업은 쉽지 않기 때문에 모델의 성능을 높이기 위해서는 무반주 라이브, 일상대화 같은 데이터가 필요하다. 따라서 모델의 성능을 높이기 위해 본인의 목소리로 무반주 노래 녹음을 진행하였고, 학습시킨 목소리를 적용시키기 위해 Youtube를 통해 가수 로이킴의 노래 10곡을 다운로드 하였다.

1.2 데이터 전처리

수집한 데이터를 모델에 학습시키기 위한 데이터 전처리 과정에는 특징 추출(Feature Extraction), 정규화(Normalization), 훈련 데이터의 다양성을 높이기 위해 데이터에 노이즈 추가, 피치 변경과 같은

데이터 증강(Data Augmentation)과정을 거친다. 마지막으로 모델 학습에 가장 중요한 분할과정이 남아 있는데, 이 부분은 데이터로 사용할 오디오 파일을 한 번에 학습시킬 경우 파일의 용량이 너무 크기 때문에 이를 15초로 나누어서 훈련 데이터를 만드는 작업을 하였다.

2. 실험

2.1 실험 방법

<Fig 1>은 전체적인 프레임워크이다. 무반주 라이브 데이터를 전처리 과정을 거치고 15초씩 분할하여 모델에 학습시킨다. 학습된 모델을 통해 변환할 로이킴의 보컬 파일을 추론하여 추론 결과 파일을 결과값으로 얻는다.

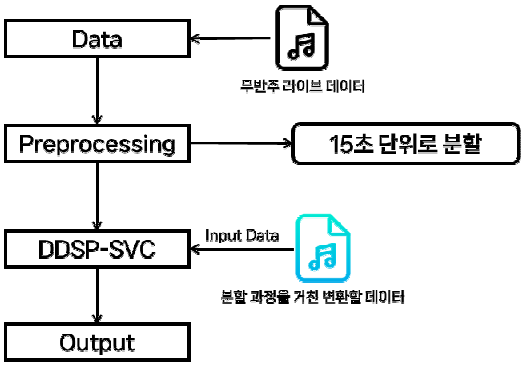

Fig. 1. System Architecture

2.2 실험 결과

본 실험에서 얻은 결과값을 바탕으로 DDSP-SVC의 성능을 평가하기 위해 F0 Pearson Correlation (FPC)를 평가지표로 사용하였다. F0는 기본 주파수를 의미하며, 보통 음성 신호의 높낮이를 나타낸다. 이러한 FPC가 높을수록 음향적으로 유사하다는 것을 의미하고, 이는 결과값에 음악적 요소(바이브레이션, 음정)를 포함하고 있다는 것을 의미한다. Table 1의 결과에서 보면 최소 0.65에서 최대 0.977의 값이 결과값으로 나왔고, 이는 노래의 특성에 따라 가성이 많이 포함된 노래에서의 FPC가 낮게 나오는 것을 확인할 수 있다.

Table 1. Experiments Results

	무반주/로이킴	무반주/DDSP	DDSP/로이킴
LoveLoveLove	0.174	0.185	0.906
그때 헤어지면 돼	0.181	0.268	0.762
그때로 돌아가	0.440	0.518	0.977
봄이 와도	0.403	0.412	0.943
북두칠성	0.576	0.598	0.829
살아가는 거야	0.266	0.437	0.895
왜 몰랐을까	0.425	0.483	0.650
우리 그만하자	0.255	0.507	0.679
잘 지내자 우리	0.570	0.452	0.971
피노키오	0.497	0.561	0.963

III. Conclusions

본 실험에서는 DDSP-SVC 모델에 무반주 라이브 데이터를 학습시켜 추론하는 과정을 통해 음성 변환을 하였다. 본 실험을 통해 최소 0.65, 최대 0.977의 FPC 값을 얻었다. 이는 적은 양의 데이터로도 충분히 음성 변환을 성공시킬 수 있다는 점을 의미한다.

본 실험에서의 한계점은 적은 양으로 양질의 결과값을 도출하는 실험을 진행하였지만, 무반주 라이브 데이터만 학습을 진행했다는 것이다. 향후 연구에서는 일상 대화 데이터를 추가적으로 학습시켜 이번 실험을 통해 추론하지 못한 소리까지 추론하는 결과를 도출할 것이다.

ACKNOWLEDGEMENT

본 연구는 2024년도 교육부의 재원으로 한국연구재단의 지원을 받아 수행된 지자체-대학 협력기반 지역혁신 사업의 결과임 (2021RIS-004)

REFERENCES

[1] DiffSVC, *https://github.com/liusongxiang/diffsvc*
[2] SO-VITS-SVC, *https://github.com/svc-develop-team/so-vits-svc*
[3] DDSP-SVC, *https://github.com/yxlllc/DDSP-SVC*